

Внешняя сортировка

Внешние сортировки

- Внешние сортировки применяются к данным, которые хранятся во внешней памяти (данные, расположенные на внешних устройствах последовательного доступа).
- Внешние сортировки применяются, если объем сортируемых данных превосходит допустимое место в ОЗУ.
- Для файлов, расположенных на таких устройствах в каждый момент времени доступен только один компонент последовательности данных, что является существенным ограничением по сравнению с сортировкой массивов, где всегда доступен каждый элемент.

Наиболее известные алгоритмы внешней сортировки:

- 1. Сортировка слиянием.
- 2. Многопутевое слияние и выбор с замещением.
- 3. Многофазное слияние.
- 4. Каскадное слияние.
- 5. Осциллирующая сортировка.
- 6. Внешняя поразрядная сортировка (или распределяющая сортировка).

Определения

- **Серия (упорядоченный отрезок)** – это последовательность элементов, которая упорядочена по ключу.
 - Количество элементов в серии называется **длиной серии**.
 - Серия, состоящая из одного элемента, упорядочена всегда.
 - Последняя серия может иметь длину меньшую, чем остальные серии файлов.
 - Максимальное количество серий в файле N (все элементы не упорядочены).
 - Минимальное количество серий одна (все элементы упорядочены).

- В основе большинства методов внешних сортировок лежит процедура слияния и процедура распределения (фазы).
- **Слияние** – это процесс объединения двух (или более) упорядоченных серий в одну упорядоченную последовательность при помощи циклического выбора элементов, доступных в данный момент.
- **Распределение** – это процесс разделения упорядоченных серий на два и несколько вспомогательных файла.

- **Фаза** – это действия по однократной обработке всей последовательности элементов.
- **Двухфазная сортировка** – это сортировка, в которой отдельно реализуется две фазы: распределение и слияние.
- **Однофазная сортировка** – это сортировка, в которой объединены фазы распределения и слияния в одну.

- **Двухпутевым слиянием** называется сортировка, в которой данные распределяются на два вспомогательных файла.

Многопутевым слиянием называется сортировка, в которой данные распределяются на N ($N > 2$) вспомогательных файлов.

Общий алгоритм сортировки слиянием

- Сначала серии распределяются на два или более вспомогательных файлов.
- Данное распределение идет поочередно: первая серия записывается в первый вспомогательный файл, вторая – во второй и так далее до последнего вспомогательного файла. Затем опять запись серии начинается в первый вспомогательный файл.

- После распределения всех серий, они объединяются в более длинные упорядоченные отрезки, то есть из каждого вспомогательного файла берется по одной серии, которые сливаются.
- Если в каком-то файле серия заканчивается, то переход к следующей серии не осуществляется.

- В зависимости от вида сортировки сформированная более длинная упорядоченная серия записывается либо в исходный файл, либо в один из вспомогательных файлов.
- После того как все серии из всех вспомогательных файлов объединены в новые серии, потом опять начинается их распределение. И так до тех пор, пока все данные не будут отсортированы.

Основные характеристики сортировки слиянием

- количество фаз в реализации сортировки;
- количество вспомогательных файлов, на которые распределяются серии.

Сортировка простым слиянием

- В данном алгоритме длина серий фиксируется на каждом шаге.
- В исходном файле все серии имеют длину 1,
- после первого шага она равна 2,
- после второго – 4,
- после третьего – 8,
- после k -го шага – 2^k .

Алгоритм сортировки простым слиянием

- Шаг 1. Исходный файл f разбивается на два вспомогательных файла f_1 и f_2 .
- Шаг 2. Вспомогательные файлы f_1 и f_2 сливаются в файл f , при этом одиночные элементы образуют упорядоченные пары.
- Шаг 3. Полученный файл f вновь обрабатывается, как указано в шагах 1 и 2. При этом упорядоченные пары переходят в упорядоченные четверки.
- Шаг 4. Повторяя шаги, сливаем четверки в восьмерки и т.д., каждый раз удваивая длину слитых последовательностей до тех пор, пока не будет упорядочен целиком весь файл

Исходный файл f: 5 7 3 2 8 4 1

	<i>Распределение</i>	<i>Слияние</i>
1 проход	<i>f1:</i> 5 3 8 1 <i>f2:</i> 7 2 4	<i>f:</i> 5 7 2 3 4 8 1
2 проход	<i>f1:</i> 5 7 4 8 <i>f2:</i> 2 3 1	<i>f:</i> 2 3 5 7 1 4 8
3 проход	<i>f1:</i> 2 3 5 7 <i>f2:</i> 1 4 8	<i>f:</i> 1 2 3 4 5 7 8

- Признаками конца сортировки простым слиянием являются следующие условия:
 - длина серии не меньше количества элементов в файле (определяется после фазы слияния);
 - количество серий равно 1 (определяется на фазе слияния).
 - при однофазной сортировке второй по счету вспомогательный файл после распределения серий остался пустым.

Анализ

- После выполнения i проходов получаем два файла, состоящих из серий длины 2^i . Окончание процесса происходит при выполнении условия $2^i \geq n$. Следовательно, процесс сортировки простым слиянием требует порядка $O(\log n)$ проходов по данным. Исходный и вспомогательные файлы будут $O(\log n)$ раз прочитаны и столько же раз записаны.
- $O(n \log n)$
- Для выполнения внешней сортировки методом простого слияния в оперативной памяти требуется расположить всего лишь две переменные – для размещения очередных элементов (записей) из вспомогательных файлов.
- Устойчивость?
- Естественность?

Однофазная сортировка простым слиянием

- Для работы алгоритма понадобятся четыре рабочие последовательности F_1 , F_2 , F_3 и F_4 и входная последовательность F .
- Сначала элементы из последовательности F распределяются в последовательности F_1 и F_2 . Затем элементы из F_1 и F_2 сливаются и одновременно распределяются в последовательности F_3 и F_4 . Далее этот процесс повторяется, но теперь сливаются элементы из F_3 и F_4 и распределяются в F_1 и F_2 .

- Последовательность F не изменяется в процессе работы, чтобы не испортить исходный файл в процессе отладки.
- Алгоритм однофазной простой сортировки экономит время, но требует большей памяти на диске по сравнению с двухфазной сортировкой.

Сортировка естественным слиянием

- Сортировка, при которой всегда сливаются две самые длинные из возможных последовательностей, является естественным слиянием. В данной сортировке объединяются серии максимальной длины.

Алгоритм сортировки естественным слиянием

- Шаг 1. Исходный файл f разбивается на два вспомогательных файла $f1$ и $f2$.
- Распределение происходит следующим образом:
 - Поочередно считываются записи a_i исходной последовательности (неупорядоченной) таким образом, что если значения ключей соседних записей удовлетворяют условию $f(a_i) \leq f(a_{i+1})$, то они записываются в первый вспомогательный файл $f1$.
 - Как только встречаются $f(a_i) > f(a_{i+1})$, то записи a_{i+1} копируются во второй вспомогательный файл $f2$.
 - Процедура повторяется до тех пор, пока все записи исходной последовательности не будут распределены по файлам.

- Признаками конца сортировки естественным слиянием являются следующие условия:
 - количество серий равно 1 (определяется на фазе слияния).
 - при однофазной сортировке второй по счету вспомогательный файл после распределения серий остался пустым.

Исходный файл *f*: 2 3 17 7 8 9 1 4 6 9 2 3 1 18

	Распределение	Слияние
1 проход	<i>f</i> 1: 2 3 17 ` 1 4 6 9 ` 1 18 <i>f</i> 2: 7 8 9 ` 2 3	<i>f</i> : 2 3 7 8 9 17 1 2 3 4 6 9 1 18
2 проход	<i>f</i> 1: 2 3 7 8 9 17 ` 1 18 <i>f</i> 2: 1 2 3 4 6 9 `	<i>f</i> : 1 2 2 3 3 4 6 7 8 9 9 17 1 18
3 проход	<i>f</i> 1: 1 2 2 3 3 4 6 7 8 9 9 17 <i>f</i> 2: 1 18	<i>f</i> : 1 1 2 2 3 3 4 6 7 8 9 9 17 18

- Естественное слияние, у которого после фазы распределения количество серий во вспомогательных файлах отличается друг от друга не более чем на единицу, называется **сбалансированным** слиянием, в противном случае – **несбалансированное** слияние(зачем).

Анализ

- Число чтений или перезаписей файлов при использовании метода естественного слияния будет не хуже, чем при применении метода простого слияния, а в среднем – даже лучше.
- Но в этом методе увеличивается число сравнений за счет тех, которые требуются для распознавания концов серий.
- Помимо этого, максимальный размер вспомогательных файлов может быть близок к размеру исходного файла, так как длина серий может быть произвольной.

- Временные затраты на любую последовательную сортировку пропорциональны длине последовательностей и числу проходов, т.к. при каждом проходе копируются все данные. Один из способов сократить затраты – распределять серии в более чем 2 последовательности (2 пути).
- Если p – число последовательностей, то число проходов $K = \log_p n$.
- Так как в каждом проходе выполняется n операций копирования, то в худшем случае: $O(t) \sim n \log_p n$.
- Такие алгоритмы называются алгоритмами **многопутевого** слияния.
- Многопутевое сбалансированное слияние (см методичку)

Внутренняя сортировка с внешним слиянием

- Рассмотрим алгоритм сортировки, который использует как внутреннюю сортировку одним из изученных ранее способов, так и слияние, присущее внешним сортировкам.
- Пусть предназначенный для сортировки файл содержит 40000 записей $R_1 \dots R_{10000}$. Пусть во внутренней памяти машины помещается одновременно только 10000 записей.
- В этом случае необходимо отсортировать во внутренней памяти каждый из четырех подфайлов $R_1 \dots R_{10000}$, $R_{10001} \dots R_{20000}$, ..., $R_{30001} \dots R_{40000}$ по отдельности, а затем слить полученные подфайлы.

- Рассмотрим работу описанного выше алгоритма на примере **алгоритма сбалансированного 4х-путевого слияния**. Нам потребуется четыре дополнительных файла.
- Файл 1 – $R1 \dots R10000$.
- Файл 2 – $R10001 \dots R20000$.
- Файл 3 – $R20001 \dots R30000$.
- Файл 4 – $R30001 \dots R40000$.

- Читаем из каждого файла (1-4) по очередной записи, выбираем из них минимальный элемент и помещаем в результирующий файл. Считываем очередной элемент из того файла, в котором был найден минимальный элемент. Процесс продолжается до тех пор, пока записи из всех 4 файлов не будут перемещены в результирующий файл.
- В этом случае алгоритм проще, чем алгоритм многопутевого сбалансированного слияния. Так как каждый из файлов (1-4) содержит по одной упорядоченной серии.